

AI 组能力测试

1 通用提交与规范说明

1. **提交物原则**：阶段一提交”调研/综述型报告”；阶段二提交”实战/复现/工程实现 + 复盘分析”。
2. **引用规范**：报告中涉及的观点、公式、数据、图表必须标注原始来源（论文/官方文档/代码仓库等）。
3. **可复现性**：给出环境与版本信息（Python、PyTorch/CPU 等），并提供可运行的脚本/命令（README）。
4. **结果展示**：必须包含定量指标（如 Accuracy、F1-Score 等）与至少一种可视化或案例分析（失败案例优先）。
5. **AI 使用**：若允许使用 AI 辅助（ChatGPT/Claude 等 AI 工具），需在附录/致谢中说明使用范围（如检索、总结、润色），并确保核心技术表述自洽且可追溯。
6. **建议交付形态**：PDF 报告 + GitHub 仓库链接（含代码、配置、日志、关键结果截图/可视化）。

2 方向一：自然语言处理（NLP）

2.1 总体目标

围绕文本分类/情感分析任务，建立从传统方法到深度学习的技术演进认知，并完成一个完整的情感分析项目。

2.2 阶段一：文献综述与任务认知

2.2.1 任务要求

围绕”Text Classification / Sentiment Analysis”展开，报告需包含核心任务的定义、输入输出及评价指标：

1. **基础任务**：文本分类（Text Classification）、情感分析（Sentiment Analysis）。
2. **进阶任务（可选）**：命名实体识别（NER）、关系抽取（RE）、文本生成（Text Generation）。
3. **技术演进路线**：
 - 传统方法：Bag-of-Words + SVM/Naive Bayes → TF-IDF + LR
 - 深度学习：Word2Vec + CNN/LSTM → BERT → GPT 系列
4. **关联分析（核心加分项）**：不同方法之间的递进关系，各方法的优缺点对比。

思考提示：传统方法和深度学习方法的本质区别是什么？为什么预训练模型能取得更好的效果？

AI 使用规范：允许并鼓励使用 ChatGPT/Claude 等 AI 工具辅助查阅资料和总结。

2.2.2 文献要求

阅读 5-8 篇核心文献（可包含经典论文和最新 SOTA）。

2.2.3 提交物

PDF 文献综述（建议 5-8 页）。

2.3 阶段二：情感分析实战

2.3.1 赛题

二分类情感分析（正面/负面）。

2.3.2 数据集

IMDB 影评数据集（50,000 条，已划分 train/test）。

2.3.3 评价指标

测试集上的 Accuracy 和 F1-Score。

2.3.4 实施路径（二选一）

路径 A：工程能力

- 使用预训练 BERT 模型进行微调
- 核心挑战：理解 BERT 的输入输出格式，正确设置微调参数
- 目标：达到 90%+ 准确率

路径 B：算法思维

- 从 Word2Vec+LSTM 实现
- 核心挑战：理解词向量、序列模型的工作原理
- 目标：对比不同模型的效果差异

2.3.5 核心产出

Part 1: 实验设置与基础结果

- 环境清单：Python、PyTorch/TF 版本
- 量化结果：汇报你在测试集上跑出的最高 Accuracy 和 F1-Score
- 注：如果你选择了路径 B，请分别列出不同模型的结果，并分析差异原因

Part 2: 策略与洞察（加分关键区）

- **错误案例分析**：主动挑选分错的样本，分析原因（例如：是文本太短？包含否定词？还是领域特殊？），并提出改进猜想。
- **模型对比分析**：如果尝试了多种方法，对比它们的优缺点。
- **训练过程记录**：记录你的调参逻辑和解决 Bug 的过程。

提示：一个 Accuracy 为 85% 但能深刻分析”为什么某些样本分错”的报告，比一个 Accuracy 为 90% 但只有一行”结果如表所示”的报告，得分会高得多。

3 方向二：多模态

3.1 总体目标

围绕视觉问答（VQA）任务，理解图文多模态融合技术，并完成 VQA 推理任务。

3.2 阶段一：文献综述与任务认知

3.2.1 任务要求

围绕”Visual Question Answering (VQA)” 展开，报告需包含：

1. **基础任务**：VQA 定义、输入输出形式、评价指标（Accuracy、VQA Score 等）。
2. **进阶任务（可选）**：
 - 图像描述生成（Image Captioning）
 - 视觉推理（Visual Reasoning）
 - 多模态对话（Multimodal Dialogue）
3. **技术演进路线**：
 - 早期方法：CNN+LSTM 拼接 → attention 机制
 - 预训练模型：CLIP → BLIP → LLaVA → Qwen-VL
4. **关联分析（核心加分项）**：不同 VQA 方法的优缺点，多模态融合的关键技术。

思考提示：多模态模型是如何将图像和文本结合在一起的？attention 机制在其中起什么作用？

3.2.2 文献要求

阅读 5-8 篇核心文献。

3.2.3 提交物

PDF 文献综述（建议 5-8 页）。

3.3 阶段二：VQA 实战

3.3.1 赛题

使用预训练模型完成 VQA 推理（无需后训练）。

3.3.2 数据集

提供 10 张图片 + 对应问题（已准备好的小测试集）。

3.3.3 评价指标

回答正确率 (Accuracy)。

3.3.4 任务要求

1. 使用 BLIP 或类似预训练模型
2. 对 10 张图片 + 问题进行推理
3. 记录模型的回答，分析对错原因

3.3.5 核心产出

Part 1: 实验设置与基础结果

- 环境配置说明
- 运行脚本
- 10 条推理结果

Part 2: 策略与洞察

- 分析模型答对/答错的原因
- 思考：模型在什么类型的问题上表现好/不好？

3.3.6 可选加分项

- 尝试修改 prompt 或输入方式，观察效果变化
- 搭建简易 Web 界面 (Gradio/Streamlit)

4 方向三：计算机视觉 (CV)

4.1 总体目标

围绕图像分类任务，建立从传统方法到深度学习的技术演进认知，并完成一个完整图像分类项目的训练。

4.2 阶段一：文献综述与任务认知

4.2.1 任务要求

围绕”Image Classification”展开，报告需包含：

1. **基础任务**：图像分类定义、输入输出、评价指标（Accuracy、Top-5 Accuracy 等）。

2. **进阶任务（可选）**：

- 目标检测（Object Detection）
- 图像分割（Image Segmentation）
- 图像生成（Image Generation）

3. **技术演进路线**：

- **经典方法**：LeNet（1998）→ AlexNet（2012）→ VGG（2014）→ GoogLeNet（2014）
- **深度残差**：ResNet（2015）→ DenseNet（2017）→ ResNeXt（2017）
- **轻量化网络**：MobileNet（2017）→ ShuffleNet（2018）→ EfficientNet（2019）
- **Transformer 时代**：Vision Transformer (ViT)（2020）→ DeiT → Swin Transformer（2021）

4. **关联分析（核心加分项）**：从 AlexNet 证明深度学习的有效性，到 ResNet 解决深度网络训练问题，再到 ViT 引入注意力机制。

思考提示：为什么 ResNet 能训练更深的网络？ViT 和 CNN 的本质区别是什么？

4.2.2 文献要求

阅读 5-8 篇核心文献。

4.2.3 提交物

PDF 文献综述（建议 5-8 页）。

4.3 阶段二：图像分类实战

4.3.1 赛题

CIFAR-10 图像分类（10 类，60,000 张图片）。

4.3.2 评价指标

测试集上的 Accuracy。

4.3.3 实施路径（二选一）

路径 A：工程能力

- 使用 PyTorch 从零搭建 ResNet
- 核心挑战：理解网络结构、训练流程、损失函数设置
- 目标：达到 85%+ 准确率

路径 B：算法思维

- 使用不同模型（如 ResNet vs VGG）对比
- 核心挑战：分析不同网络结构的设计思想和效果差异
- 目标：理解不同结构的优缺点

4.3.4 核心产出

Part 1: 实验设置与基础结果

- 环境清单：CUDA、PyTorch 版本及硬件配置
- 量化结果：汇报你在测试集上跑出的最高 Accuracy
- 注：如果你选择了路径 B，请分别列出不同模型的结果，并计算差异

Part 2: 策略与洞察（加分关键区）

- **错误案例分析**：主动挑选分错的图片，分析原因（例如：是图片模糊？类别相似？还是数据不均衡？），并提出改进猜想。
- **模型对比分析**：对比不同网络结构的效果差异及原因。
- **训练过程记录**：记录你的调参逻辑（例如：“我观察到 loss 震荡，所以降低了学习率...”）。
- **Trade-off 思考**：分析模型大小与准确率的平衡。

提示：一个 Accuracy 为 83% 但能深刻分析“为什么某些类别的图片分错”的报告，比一个 Accuracy 为 88% 但只有一行“结果如表所示”的报告，得分会高得多。

4.3.5 可选加分项

- 使用数据增强（旋转、翻转、裁剪等）
- 可视化训练过程（loss 曲线、accuracy 曲线）
- 可视化卷积核或特征图

5 评分标准

5.1 阶段一（综述报告）

- **完整性**（40%）：是否覆盖所有要求的内容
- **准确性**（30%）：技术描述是否正确
- **深度**（20%）：关联分析是否有洞见
- **规范性**（10%）：引用格式、排版是否规范

5.2 阶段二（实战项目）

- **代码质量**（30%）：代码是否可运行、结构是否清晰
- **实验结果**（30%）：是否达到基本指标
- **分析深度**（30%）：错误案例分析、模型对比是否有价值
- **创新性**（10%）：是否有额外的探索和尝试

6 时间安排建议

阶段	内容	建议时间
阶段一	文献阅读 + 综述撰写	3-5 天
阶段二	实战任务 + 复盘报告	4-7 天

表 1: 时间安排

7 注意事项

1. 所有代码、输出结果等保存到一个大文件夹下，作为最终项目文件

2. 提交要求：将代码文件上传至 GitHub 并给出链接
3. 阶段一综述和阶段二报告整合为一份 PDF 提交
4. 鼓励使用云算力节省环境调试时间
5. 代码可以直接搬现有开源项目的用，但是项目总体需要从 0 开始搭建